Pesquisa externa II: persuasão, conversão e como construir um agente que substitui um humano

> **Data:** 2026-10-21. **Status:** pesquisa, nada virou código. Continua a pesquisa I a pedido do operador: mais fundo em **persuasão e conversão** e em **estrutura e configuração de agentes de IA que igualem um humano**. Cruzado com o script v3 e a análise de arquitetura. **Método:** cerca de 20 buscas + leitura direta de dois textos primários da Anthropic. Fonte secundária está marcada.

0. A resposta curta

1. **"Igual a um humano" não está provado em lugar nenhum.** Os melhores dados mostram que a IA **nivela por baixo e por volume**: ajuda muito o atendente novato (+34%), pouco o experiente, e perde para o humano em qualidade (taxa de resposta, reunião marcada), mas ganha em custo. O alvo realista para a Malu é **custo por pedido entregue ≤ o do humano**, não "vender igual ao melhor vendedor". Para isso precisamos do número do humano (§3, item 1).
2. **A estrutura que a literatura recomenda é a que o projeto já escolheu**: fluxo determinístico com gates em volta do modelo, estado fora do modelo, laço de avaliar-e-reescrever. O ganho agora não está em arquitetura nova, está em **medir confiabilidade (não só média)** e em **ajustes de persuasão no texto**.
3. **A maior alavanca de persuasão que a pesquisa sustenta é tirar pressão**, não adicionar gatilho: em texto, linguagem que ameaça a liberdade da pessoa gera reação contrária. Isso muda como a Malu responde "vou pensar" e como a régua cobra.
4. **Um achado que importa para a política da Malu**: bot **anunciado de cara** derrubou compra em ~80% num experimento de campo; bot **não anunciado** igualou vendedor competente. A regra do projeto (nunca afirma ser humana, não anuncia, responde honesto se perguntada) é a posição defensável. Ver §1.6.

1. Persuasão e conversão: o que tem evidência, e o limite de cada uma

Tamanhos de efeito importam. Quase tudo em persuasão é **pequeno**, e a literatura sensacionalista omite isso.

#	Princípio	O que a pesquisa diz	Aplicação na Malu
1.1	**Reatância** (a pessoa resiste quando sente a liberdade ameaçada)	Meta-análise de 146 efeitos (2005–2024): linguagem de pressão aumenta raiva e pensamentos negativos e **reduz persuasão**, r≈0,20. O efeito é **maior em texto puro** que em vídeo/áudio (SSRC/MediaWell, via resumo)	WhatsApp é texto. Trocar "aproveita agora", "garanta já" por moldura que devolve o controle: "fica à vontade", "se fizer sentido pra você". Vale para a régua de follow-up
1.2	**Perguntas calibradas e rótulo da emoção** (Voss)	Pergunta que deixa dizer **não** gera conforto e abre a conversa. Fontes secundárias, sem dado de venda por texto (resumo)	"Vou pensar": "Parece que sobrou alguma dúvida. É o valor, o tamanho ou a entrega?" em vez de insistir
1.3	**Gong Labs, objeções**	67 mil chamadas: os melhores vendedores **pausam mais e perguntam** antes de responder. O medíocre despeja monólogo de ~21 s. Correlação, não causa (Gong)	Objeção vaga = uma pergunta curta, não um parágrafo de argumentos
1.4	**Prova social**	Mostrar avaliações eleva muito a compra: produto com 5 avaliações tem 270% mais chance de compra que sem	Não achei teste de depoimento específico vs. genérico. Manter só avaliação real.

#	Princípio	O que a pesquisa diz	Aplicação na Malu
		nenhuma, num varejista de presentes (Spiegel, via resumo). Fonte secundária diz que notas entre 4,0 e 4,7 inspiram mais confiança que 5,0	**Rever "nota 5"** se a nota real tiver variação: uma nota perfeita pode soar falsa (afirmação não verificada)
1.5	**Pé na porta / porta na cara**	Meta-análise: efeitos **pequenos** (r≈0,17 e 0,15), exigem causa pró-social, e a porta na cara só funciona com intervalo curto (Dillard et al., via resumo). Uma réplica de 2014 não encontrou o efeito	O v3 já usa micro-passos (tamanho, CEP, nome) por facilidade (Fogg), não por "compromisso". Não esperar salto. Não montar a conversa em torno disso
1.6	**Divulgação de IA**	Experimento de campo, ~6.200 clientes, ligações de venda: bot **sem aviso** igualou o vendedor proficiente e superou o novato; **avisar antes** reduziu a compra em 79,7% (Luo et al., Marketing Science 2019). Era ligação ativa (a empresa ligou), não cliente que chega do anúncio	Confirma a regra do projeto: **não anunciar, nunca negar** (R2.3). Nunca "sou uma pessoa". O dado não autoriza mentir, e a cliente de anúncio já veio sozinha
1.7	**Personalização**	GPT-4 com dados do oponente venceu o humano em 64,4% dos debates em que um dos dois convenceu (900 pessoas, Nature Human Behaviour 2025). **Debate político**, não venda (Salvi et al.)	A alavanca é usar o que **ela disse na conversa** (ocasião, tamanho, cidade). Só dado que ela deu
1.8	**Âncora, isca, kit**	O estudo clássico da isca (Economist) é de questionário, não de receita medida (resumo)	A régua de preço do kit (1, 2 e 3 peças) já existe e os valores são reais. Não vender como "truque"
1.9	**Preço depois de entender**	Gong: ganho maior quando preço aparece em chamada longa após descoberta (fonte secundária, B2B). SPIN (35 mil chamadas): táticas de fechamento servem em **venda barata**; descoberta funda é para venda grande (Rackham, resumo)	Colete de R$ 130 é compra de impulso. **Não importar** "11–14 perguntas de descoberta" de B2B. Uma pergunta bem posta basta

O ponto menos óbvio: o modelo também é persuadível

Equipe com Cialdini testou os 7 princípios em ~28.000 conversas com um modelo: com o gatilho (autoridade, compromisso, prova social…), a obediência a pedidos que ele recusaria subiu de **33% para 72%** (Wharton GAIL; versão preliminar, modelo pequeno). Para a Malu isso é o risco inverso: a **cliente** (ou um golpista) pode usar "sou da Meta", "a Ana já tinha liberado desconto", "todo mundo ganha frete grátis" para empurrar o modelo. O que protege é o que o projeto já tem, a ação em código e os gates. Falta um teste por persona de **pressão por autoridade** (§3, item 6).

2. Como estruturar um agente que chegue perto de um humano

2.1 O que a evidência diz sobre "substituir"

Fonte	Achado	Leitura para nós
Brynjolfsson, Li e Raymond (NBER 2023)	5.179 atendentes: IA assistente subiu a produtividade ~14%, **34% nos novatos**, quase nada nos experientes	A IA **eleva o piso**, não o teto. A régua deve ser o vendedor mediano
Klarna, via imprensa	IA fez o trabalho de ~700 atendentes, resolução de 11 min para 2. Em 2025 o CEO admitiu que o custo pesou demais e a qualidade caiu; voltou a contratar e garante "sempre há um humano"	Custo como único critério degrada. Mantém a lição: caminho para uma pessoa é decisão de projeto. **Atenção**: a regra R22.1 da Malu é nunca chamar pessoa; o que ela não resolve vai por e-mail. Vale revisitar quando houver volume

Fonte	Achado	Leitura para nós
Comparação pareada, 100 mil e-mails	IA: resposta 4,1% vs 5,2% humano; reunião 0,7% vs 1,1%; custo por reunião bem menor (blog de fornecedor)	Padrão repetido: humano ganha em qualidade, IA em custo e volume. Híbrido é a recomendação, sem estudo independente
Air Canada, tribunal 2024	A empresa foi obrigada a honrar reembolso inventado pelo chatbot; "o chatbot é entidade separada" foi rejeitado	Confirma que garantia, prazo, frete e desconto precisam ser gate. A promessa da Malu é a promessa da Encorpa

2.2 Estrutura recomendada (Anthropic) contra o que o projeto tem

Fonte primária: Building effective agents e Effective context engineering.

Recomendação	O projeto
Comece simples; só acrescente complexidade se a medição provar	Decidido (R11: sem tool-calling, sem RAG, sem vetor)
Fluxo com portões em código entre as etapas (*prompt chaining*) e **avaliar-e-reescrever**	É a cadeia de gates com veto e reescrita (até cinco tentativas, R22.2)
Guardrail em paralelo à resposta, não dentro dela	Gates são código, fora do modelo
Prompt na "altitude certa": nem regra frágil, nem vago. **Poucos exemplos canônicos valem mais que lista de regras**	O próprio plano 12 achou o prompt com regra de estilo demais produzindo texto longo (C7, R3). A Anthropic aponta o mesmo
Contexto é finito; manter notas fora da janela e recuperar só o necessário	Fato durável do lead em `jsonb` por extrator determinístico (R11.5)
Interface das ferramentas como docstring para júnior; desenhar para dificultar o erro	Aplica-se às ações em código (checkout, cobertura)
Parada e supervisão humana em ação irreversível	Hermes propõe, operador aprova (R14.14)

2.3 Três riscos que a literatura traz e o projeto ainda não mede

1. **Conversa longa degrada o modelo.** Em 200 mil conversas simuladas, os modelos caíram em média **39%** do uso de uma mensagem para várias, a maior parte por **instabilidade** (+112%), não por falta de capacidade. Eles assumem cedo, tentam responder cedo e **não se recuperam** de um passo errado. Baixar a temperatura e repetir a instrução não resolveu (Laban et al., Microsoft/Salesforce). Resposta: manter o estado **fora** do modelo (já existe) e **reinjetar um bloco compacto de fatos do lead a cada turno** (tamanho, CEP, cobertura, ocasião, objeções já ditas), em vez de confiar no histórico bruto.
2. **A média esconde a inconsistência.** O benchmark τ-bench (Sierra) mede **pass^k**: acertar a **mesma tarefa k vezes seguidas**. Para um modelo da geração anterior, ~61% numa rodada caía para ~25% em oito (números de fonte secundária, resumo). Cliente real repete a conversa de formas ligeiramente diferentes: uma persona que passa 1 vez em 1 não prova nada.
3. **Cliente simulado desiste de menos que cliente real.** Um estudo de 2026 mediu simuladores contra compra real e alerta que o simulador **suprime resistência** e passa a premiar táticas de pressão que o cliente de verdade ignora (arXiv 2606.20708, só o resumo lido). A bateria de personas prova que os gates seguram, **não que a conversão sobe**.

2.4 O que a Intercom ensina sobre configurar (vendor, mas é o texto mais prático)

Fin Guidance: descrever **o que informar** e deixar o modelo escolher as palavras; instrução específica e acionável ("pergunte qual produto ela usa antes de responder"); **oferta de escalar situacional, não regra geral** (o geral reduz a taxa de resolução); base de conhecimento defasada limita o teto, qualquer que seja o modelo. A taxa média de resolução de 56% em 30 dias é número do fornecedor.

3. O que fazer: backlog adicional (acumula com os 7 itens da pesquisa I)

Ordem por impacto esperado sobre risco. Tudo é hipótese a medir; prompt e gate passam por `tests/prompt.test.ts` e `pnpm dev:gates`.

#	O quê	Por quê	Custo/risco
1	**Obter o número do humano**: conversão e custo por pedido entregue do fluxo manual do operador (o "FLUXO" do Drive)	Sem isso "igual a um humano" não é verificável. Define a meta	Zero de código; depende do operador
2	**Prompt e régua sem pressão** (§1.1): moldura de liberdade, nenhuma urgência fabricada, "sem pressa" explícito	Reatância; o texto puro agrava	Baixo; checar com `persona-denise` e `persona-neusa` (régua)
3	**"Vou pensar" e "tá caro" viram uma pergunta curta com rótulo** (§1.2–1.3)	Gong e Voss; liga com o achado §18 do plano 12 (recusa lida como "vou pensar")	Baixo; gate só muda por frase real (R21.6)
4	**Bloco de fatos do lead reinjetado a cada turno** (§2.3.1)	Degradação em conversa longa	Médio; olhar antes o que o `turn` já injeta
5	**Rodar cada persona N vezes e reportar pior caso e pass^k**, não só a média	§2.3.2	**Custa chamadas ao modelo da Meta**. A memória *Sem gasto de API sem pedido* exige o seu OK antes
6	**Persona de pressão por autoridade/compromisso** ("sou da Meta", "a atendente disse que...")	§1, risco inverso	Baixo; reaproveita `persona-tati` e `persona-jussara`
7	**Validar a bateria contra as conversas reais**: comparar onde as personas param com onde as 33 reais pararam (`turn_outcomes`)	§2.3.3	Sem custo de modelo; é consulta SQL
8	**Revisar a afirmação da nota** na prova social	§1.4	Conferir a nota real nas avaliações

Mantidas as cinco recusas da rodada 11: tool-calling, RAG, vetor, Hermes dentro do turno e auto-aplicar melhoria. A pesquisa só reforçou: a Anthropic recomenda o mais simples que funcione.

4. O que não achei ou não verifiquei

- **Nenhum estudo independente de "IA vendendo no WhatsApp"**, nem de recusa no pagamento na entrega, nem de áudio vs. texto.
- Cialdini, Voss, Hormozi e SPIN vieram de **resumos**, não dos livros. Gong e Anthropic, dos textos originais.
- O estudo de divulgação (Luo) é de ligação ativa, não de cliente que chega do anúncio. O de personalização (Salvi) é debate político.
- Os números do τ-bench e das comparações IA/humano são de fonte secundária ou de blog de fornecedor.
- Tudo aqui é **hipótese de teste**. Nada foi medido nos nossos dados.

5. Fontes

Anthropic: agentes · Anthropic: contexto · Laban et al. · Luo et al. · Salvi et al. · Wharton GAIL · Brynjolfsson et al. · Klarna · Air Canada · AI SDR vs humano · τ-bench · Simulador vs compra real · Intercom Fin · Gong Labs · Reatância · Pé na porta · Spiegel · Isca · Rackham · Voss