Plano de execução: as mudanças das pesquisas externas I e II

> **Data:** 2026-10-21. **Status:** plano; nada implementado. **Origem:** pesquisa I (7 lacunas) e pesquisa II (8 itens), juntadas em **14 mudanças** (M1–M14) porque três se repetiam. Cada uma responde às 7 perguntas do operador. A **§3 é o veredito**: o que segue, o que muda e o que sai. **Conferido contra o código** em 21/10 (`src/agent/prompt.ts`, `retry.ts`, `followups.ts`, `availability.ts`, `coinzz.ts`) e contra os planos 13 e 14.

0. Três restrições que valem para todas as mudanças

1. **A agente congela de 23/10 a 09/11** (L3, `14-experimentos-l3.md`): nenhum deploy de prompt, gate ou config de venda. A exceção é bug que perde venda ou que mente. Hoje é 21/10: o que mexe no texto da Malu cai em **E7, a partir de 10/11**.
2. **Toda mudança de prompt ou gate passa pela mesma régua**: espelho byte a byte em `supabase/functions/turn/`, `tests/prompt.test.ts`, `pnpm dev:gates`, `pnpm test && pnpm dev:conversas && pnpm typecheck:function`, a eval de venda (`pnpm dev:eval --compare`), entrada no grafo, e **gate só muda por frase real** (R21.6).
3. **Chamar o modelo da Meta exige o OK do operador** (memória *Sem gasto de API sem pedido*, 15/10). Toda rodada de persona abaixo traz o custo estimado.

---

1. As 14 mudanças, uma a uma

M1. O número do humano (a meta de "substituir")

1. **Objetivo:** ter a conversão e o custo por pedido entregue do funil **feito por gente** (o "FLUXO" do Drive, validado pelo operador). Isso vira a meta da Malu.
2. **Fundamento:** a IA eleva o piso, não o teto (Brynjolfsson, +34% nos novatos); IA perde para humano em qualidade e ganha em custo (comparação de 100 mil e-mails). Sem a régua humana, "igual a um humano" não é verificável.
3. **Por que não outro método:** comparar com o mercado não serve, porque os números públicos são de fornecedor e definem conversão de jeitos diferentes (pesquisa I §0). O dado do próprio operador é o único comparável.
4. **Como:** o operador informa, do período em que vendia pelo fluxo manual: leads, pedidos, pedidos entregues, recusas na porta, verba e horas gastas. Registro em `docs/agente-ia/10-auditoria/baseline-humano.md` e no grafo.
5. **Ferramentas:** planilha/relatório da Logzz e da Coinzz do operador; `technical-writer`.
6. **Impacto esperado:** nenhum na Malu. Define a régua de aprovação de E7: a Malu "substitui" quando o custo por pedido entregue fica ≤ o humano.
7. **Métricas:** conversão lead→pedido e lead→entregue, custo por pedido entregue (verba + modelo + mensagens), lado a lado humano × Malu.

M2. Frete do antecipado antes do link

1. **Objetivo:** a cliente fora da área da entrega saber o valor do frete **antes** de abrir o checkout.
2. **Fundamento:** custo extra é o motivo nº 1 de abandono, 39% (Baymard). Hoje a Malu diz "o frete aparece no checkout" (`freightBriefing`), porque não sabe o valor.
3. **Por que não outro método:** estimar uma faixa ou um valor médio é inventar número, e o projeto já errou nisso (memória *O frete do antecipado não existe*). Só serve o valor real do checkout.
4. **Como:** (a) o tópico (b) do `HANDOFF.md` (Playwright na Coinzz) prova se o frete por região é legível por GET. (b) Se for, `lookupRegion` (`availability.ts`) devolve `prepayFreightBrl`; `freightBriefing` ganha a frase com o valor, só quando ele veio da consulta, e o gate de frete aceita o número igual ao da consulta. Falha da consulta continua "aparece no checkout".
5. **Ferramentas:** Playwright, `availability.ts` / `coinzz.ts` + espelho, `prompt.ts`, `guardrails.ts`; `backend-specialist` e `pricing-guardian` (Opus); `code-reviewer`.
6. **Impacto esperado:** mais pedidos no antecipado entre quem recebeu o link. Risco: latência da consulta e número errado (custo de reputação).
7. **Métricas:** no caminho antecipado, link enviado → pedido criado; % de conversas em que ela pergunta "quanto é o frete" depois do link; latência p90 do turno com consulta.

M3. Pergunta sobre ela e uso do que ela conta

1. **Objetivo:** a Malu soar como alguém que presta atenção: usar a ocasião ou o incômodo que ela contou ("vestido de festa", "pós-parto").
2. **Fundamento:** quem faz perguntas de acompanhamento é mais bem visto (Huang et al., d≈0,35); personalização aumentou a persuasão do modelo (Salvi et al., debate).
3. **Por que não outro método:** o caminho pesado (lead score, perfil inferido) já foi recusado no plano 12 por não decidir nada. O caminho leve é o modelo reaproveitar o que ela escreveu.
4. **Como:** uma linha no `systemPrompt`: "quando ela contar pra que quer o colete, use isso na resposta seguinte e na oferta". **Não** acrescentar pergunta nova à abertura do v3. Eval antes do deploy; depois, braço A/B.
5. **Ferramentas:** `prompt.ts` + espelho, `tests/prompt.test.ts`, `pnpm dev:eval --compare` (cenários de `src/dev/scenarios/venda.json` com ocasião), `prompt-engineer`.
6. **Impacto esperado:** mais resposta depois da abertura e menos "parou na 1ª resposta". Risco baixo.
7. **Métricas:** % que responde à 1ª pergunta da Malu; % que chega ao CEP; na eval, nota do eixo "personalização" (quando o juiz E4.3 existir).

M4. Objeção vaga: rótulo e uma pergunta curta

1. **Objetivo:** em "tá caro", "achei mais barato" e "vou ver", entender a objeção real antes de argumentar.
2. **Fundamento:** os melhores vendedores pausam e perguntam antes de responder; o mediano despeja monólogo (Gong, 67 mil chamadas). Rótulo e pergunta "o que/como" (Voss).
3. **Por que não outro método:** a lista de argumentos já existe (`objectionBriefing`) e responde a objeção presumida. Uma pergunta custa uma troca e acerta a objeção certa.
4. **Como:** no `objectionBriefing`, o item "tá caro" ganha: "rotule e pergunte uma vez o que pesa mais, o valor ou a dúvida se serve, antes dos argumentos". **"Vou pensar" fica como está** (`THINK_REPLY`, decisão R16.5 + E1.1: não insistir, não emendar pergunta).

5. **Ferramentas:** `prompt.ts` + espelho, `tests/prompt.test.ts`, `pnpm dev:gates`, `persona-tati`, `prompt-engineer`.
6. **Impacto esperado:** menos conversa perdida depois de "tá caro". Risco: soar como interrogatório.
7. **Métricas:** das conversas com "tá caro", % que chega ao link; opt-out depois da pergunta.

M5. Moldura sem pressão (prompt, textos fixos e régua)

1. **Objetivo:** nenhum texto da Malu soar como cobrança ou pressão.
2. **Fundamento:** meta-análise de 146 efeitos: linguagem que ameaça a liberdade reduz persuasão (r≈0,20), e o efeito é **maior em texto**.
3. **Por que não outro método:** acrescentar gatilho de urgência é o oposto do que a evidência mostra e já foi retirado (E1.4, R20.1).
4. **Como:** auditoria **só de leitura** dos textos fixos (`retry.ts`, `followups.ts`, `opt-in.ts`) e do prompt, atrás de imperativo de pressão ("garanta", "aproveite", "não perca", "corre"). Encontrou, troca por moldura de escolha em E7.
5. **Ferramentas:** `git grep`, `conversation-designer`, `persona-neusa` e `persona-denise` (régua).
6. **Impacto esperado:** menos opt-out e menos silêncio depois de um toque da régua.
7. **Métricas:** opt-out por tipo de toque (`silence_1/2/3`, `checkout_reminder`); resposta em até 24 h depois de cada toque.

M6. Reversor de risco na abertura da resposta à desconfiança

1. **Objetivo:** quando ela desconfia, a primeira frase é "você só paga quando o colete chegar".
2. **Fundamento:** reversão de risco (Hormozi); confiança como causa de abandono (Baymard).
3. **Por que não outro método:** não há método melhor, porque o pagamento na entrega é o reversor mais forte que existe.
4. **Como: já existe**: `objectionBriefing` manda acolher ("É justo desconfiar") e provar com o pagamento na entrega e os 7 dias.
5. **Ferramentas:** nenhuma nova; conferir na eval com `persona-jussara`.
6. **Impacto esperado:** nenhum adicional.
7. **Métricas:** das conversas com "golpe/confiável", % que chega ao CEP.

M7. Preço do kit por peça

1. **Objetivo:** mostrar o preço por peça do kit para ancorar.
2. **Fundamento:** âncora de preço em pacote (evidência fraca: o estudo da isca é de questionário).
3. **Por que não outro método:** a régua de preço 1/2/3 peças já é a âncora.
4. **Como:** frase no `kitsBriefing`. **Problema achado:** 2 peças na entrega saem R$ 116,91 cada, **o mesmo número do antecipado de 1 peça**. Os dois preços se confundem na mesma conversa.
5. **Ferramentas:** `pricing-guardian`.
6. **Impacto esperado:** incerto; risco de confusão de preço.
7. **Métricas:** taxa de kit nos pedidos.

M8. Confirmação na véspera da entrega

1. **Objetivo:** diminuir a recusa na porta.

2. **Fundamento:** fornecedor estima devolução de 20–30% → 10–15% com confirmação prévia (sem estudo independente).
3. **Por que não outro método:** não há; confirmar é o método.
4. **Como: já existe**: o toque `order_eve` em `followups.ts` (véspera do pedido).
5. **Ferramentas:** nenhuma nova.
6. **Impacto esperado:** já no ar; falta medir.
7. **Métricas:** recusa na porta por caminho, com e sem resposta ao `order_eve` (E6.3, item 5).

M9. Lembrete pouco depois do link

1. **Objetivo:** recuperar quem recebeu o link e não pagou.
2. **Fundamento:** cadência de recuperação de fornecedor (1º toque entre 10 min e 1 h, sem desconto).
3. **Por que não outro método:** a régua de silêncio já cobre os dias seguintes.
4. **Como: já existe**: `checkout_reminder` sai 10 min depois do link (`CHECKOUT_REMINDER_MS`). As fontes divergem entre 10–15 min e 1 h: nenhuma prova que 1 h seja melhor.
5. **Ferramentas:** nenhuma nova.
6. **Impacto esperado:** nenhum adicional.
7. **Métricas:** link → pedido, antes e depois do `checkout_reminder`.

M10. Bloco de fatos do lead reinjetado a cada turno

1. **Objetivo:** a Malu não repetir, não esquecer e não se perder em conversa longa.
2. **Fundamento:** em várias trocas, o modelo cai em média 39% e não se recupera de um passo errado (Laban et al.); a Anthropic recomenda notas fora da janela.
3. **Por que não outro método:** memória vetorial e RAG foram recusados (R11.4, R11.5); o fato durável já mora em `jsonb`.
4. **Como: já existe em parte**: cada turno recebe `sizeDirective`, `identityDirective`, `checkoutDirective` e a linha dos fatos do link. Falta "o que já foi respondido" (objeções e dúvidas). Acrescentar só se a medição mostrar repetição.
5. **Ferramentas:** `persona-scorecard.ts` (métrica de repetição), `index.ts` da `turn`, `backend-specialist`.
6. **Impacto esperado:** menos "ouvir a mesma coisa duas vezes", que o prompt lista como o que afasta a cliente.
7. **Métricas:** % de conversas com resposta repetida (n-grama entre balões da Malu); conversas com 10+ trocas que chegam ao link.

M11. Confiabilidade: pass^k em vez de média

1. **Objetivo:** aprovar uma versão só se ela acerta **toda vez**, não na média.
2. **Fundamento:** τ-bench: ~61% numa rodada cai para ~25% em oito (fonte secundária).
3. **Por que não outro método:** a eval já compara médias (`dev:eval --compare`); a média esconde o pior caso, e o pior caso é o que custa frete.
4. **Como:** rodar a suíte de venda e as personas críticas **3 vezes** por versão candidata e reportar o pior caso e o pass^3 no `_placar.json`. Só nas comparações de E7.
5. **Ferramentas:** `persona-run-core.ts`, `persona-scorecard.ts`, `persona-eval.ts`, `test-engineer`. **Custo:** ~R$ 1,5 por rodada completa (HANDOFF, tópico d) × 3 ≈ R$ 4,5 por versão.

6. **Impacto esperado:** menos regressão que só aparece com cliente real.
7. **Métricas:** pass^3 por cenário; nº de barreiras (mentira, opt-out ignorado) no pior caso.

M12. Persona de pressão por autoridade

1. **Objetivo:** provar que a Malu não cede quando a cliente usa autoridade, compromisso ou prova social contra ela ("sou da Meta", "a atendente já tinha liberado desconto").
2. **Fundamento:** os princípios de Cialdini dobraram a obediência de um modelo, de 33% para 72% (Wharton). A promessa do chatbot obriga a empresa (Air Canada).
3. **Por que não outro método:** a proteção já é o código (gates). O que falta é a prova, e a persona é a forma que o projeto já usa.
4. **Como:** novo arquivo em `.claude/agents/` (ou casos novos em `persona-tati`/`persona-jussara`), rodado **junto** da rodada de personas na v35 já prevista antes do L3 (tópico d do `HANDOFF.md`).
5. **Ferramentas:** `conversation-designer` (roteiro), `pnpm dev:personas`, `pnpm dev:placar`.
6. **Impacto esperado:** nenhum se os gates segurarem; um bug de mentira achado antes do L3 se não segurarem.
7. **Métricas:** concessão indevida (desconto, frete, prazo) = 0; vetos disparados.

M13. A bateria de personas contra as conversas reais

1. **Objetivo:** saber se a persona prevê a cliente real.
2. **Fundamento:** cliente simulado desiste menos que o real e premia pressão (arXiv 2606.20708).
3. **Por que não outro método:** o comprador com propensão oculta (E4.1, `sales-buyer.ts`) já existe para isso. Falta calibrá-lo com dado real.
4. **Como:** no fim do L3, comparar onde as conversas reais param (`conversations.stage`, `turn_outcomes`) com onde a suíte de venda para; ajustar as regras de subida e descida da propensão.
5. **Ferramentas:** SQL nas views de avaliação (`0018`), `sales-buyer.ts`, `test-engineer`.
6. **Impacto esperado:** a eval passa a prever conversão, não só segurança.
7. **Métricas:** distância entre a distribuição real e a simulada do ponto de parada, por estágio.

M14. Prova social que se sustenta

1. **Objetivo:** só citar número que tenha prova arquivada.
2. **Fundamento:** prova social eleva a compra (Spiegel), e nota perfeita pode soar falsa (fonte secundária). O parecer de conformidade de 19/10 já marcou "500 clientes" e "124 avaliações" sem prova arquivada.
3. **Por que não outro método:** tirar a prova social perde a alavanca mais forte; o caminho é provar.
4. **Como:** o operador arquiva a origem dos números (relatório da Logzz, plataforma de avaliações) em `docs/operacao/`; o que não tiver prova sai de `socialProof` no `BUSINESS_CONFIG`. Sem mudança de código: o prompt já lê o config.
5. **Ferramentas:** `compliance-reviewer`, `BUSINESS_CONFIG` (JSON validado + hash + `job:"health"`).
6. **Impacto esperado:** nenhuma queda prevista; elimina risco jurídico (CDC art. 37) antes de gastar verba.
7. **Métricas:** número citado = número arquivado (sim/não).

---

2. Calendário

Quando	O quê
21–22/10 (antes do L3, sem deploy de prompt)	M1 (operador), M14 (operador + config), M12 (roda na rodada de personas do tópico d), M5 (só auditoria)
23/10–09/11 (L3, agente congelada)	Só medir: link → pedido por caminho (M2), objeções reais (M4), resposta por toque (M5), recusa por caminho (M8), ponto de parada real (M13)
10/11 em diante (E7)	M13 (calibrar), depois M11 como régua; com ela, M2, M3, M4 e M10, um de cada vez, cada um com eval e braço A/B

---

3. Passos para trás: o veredito

Reli as 14 respostas contra três perguntas: **já existe? a evidência sustenta o custo? cabe no calendário?** Quatro eram coisas que o código já faz, uma estava em conflito com o funil validado, e as de prompt não podem entrar antes de 09/11.

#	Veredito	Motivo
M1	✅ **PROSSEGUIR já**	Custo zero, define a meta de todo o resto. Sem ele, nenhuma decisão de E7 tem régua
M14	✅ **PROSSEGUIR já, antes do L3**	É risco jurídico apontado pelo parecer; o L3 vai pôr verba em cima do número. Não é mudança de código
M12	✅ **PROSSEGUIR já**, dentro da rodada do tópico d	Achar um furo de mentira antes do L3 é a exceção que o L3 aceita. Custo marginal, porque a rodada já está prevista
M5	🔄 **ADAPTAR**: só auditoria agora, mudança em E7	A evidência é a mais forte das duas pesquisas, mas o sistema já tirou escassez e pressão (E1.4, R20.1, régua v3). Mexer sem achar pressão seria mudar por mudar
M13	🔄 **ADAPTAR**: depois do L3, e antes de M11	Não há conversa real depois do v3 para comparar. É o que torna a eval confiável para as mudanças de E7
M11	🔄 **ADAPTAR**: k=3, só nas comparações de E7, com OK de custo	pass^8 custaria ~R$ 12 por versão sem ganho proporcional. Rodar repetido antes de M13 mediria um simulador não calibrado
M2	🔄 **ADAPTAR**: depende do tópico (b) e do dado do L3	Só vale se o frete for legível de verdade (sem número inventado) e se o L3 mostrar link antecipado → pedido baixo
M4	🔄 **ADAPTAR**: só "tá caro", nunca "vou pensar"	Perguntar depois de "vou pensar" contraria R16.5 e E1.1 (recusa respeitada), que vieram de conversa real. "Tá caro" não tem essa história
M10	🔄 **ADAPTAR**: medir repetição primeiro	Os diretivos de estado já existem; acrescentar contexto sem medir é peso a mais no prompt
M3	🔁 **SUBSTITUIR** a "pergunta extra" por "usar o que ela conta"	13 de 33 clientes pararam na 1ª resposta quando a Malu pedia algo; o v3 vende antes de perguntar. A versão sem pergunta nova pega o ganho de atenção sem pedir esforço
M6	❌ **DESCARTAR**	Já está em `objectionBriefing`
M8	❌ **DESCARTAR** como construção	`order_eve` já existe; fica só a métrica (E6.3)
M9	❌ **DESCARTAR**	`checkout_reminder` já sai em 10 min; nenhuma fonte prova que 1 h seja melhor
M7	❌ **DESCARTAR**	O preço por peça do kit de 2 (R$ 116,91) é igual ao antecipado de 1 peça: confunde. A evidência da âncora é fraca e o estoque do kit está pendente (tópico h)

Prosseguimos com: M1, M14 e M12 agora. M5 em auditoria agora. No L3, só medição. Em E7, na ordem M13 → M11 → (M2, M3', M4', M10) conforme os dados do L3 apontarem onde mais se perde.

Antes de executar: cada item que entra vira entrada no grafo de decisões, e o quadro do `HANDOFF.md` ganha a linha "pesquisas I e II: M1/M12/M14".